

數學題目系統

由試卷 PDF 到學生手寫頁：
把每一條題目變成可分析、可比較、可跟進的數據



對象: 學校數學老師 × 技術同事 · 20 分鐘


現況:一份卷改完之後,留下的是

- 分數和對錯。「Q24 ✕」——但錯在認不出、算不對,還是接不上?
- 靠經驗的難度。這份卷「難」在哪裡,兩位老師未必同意;兩份卷是否同等難度,憑感覺。
- 用完即棄的題目。去年那條「考頂點的好題」,今年靠記憶去找。
- 看不見的過程。學生的手寫頁只換來一個 ✓ 或 ✕,走了哪條路、哪一步斷了,沒有記錄。

目標:每一條題目、每一張答卷,都變成數據

- 題目→ 六個可觀察的難度維度(RPDICE)+ 用到的技能 + 會暴露的錯誤,全部對回課程指引。
- 答卷→ 走了哪條解題路線、哪些技能有紙上證據、錯在哪一類。
- 資料庫→ 可以搜、可以比、可以累積;下一年出卷不用從零開始。
- 分工→ AI 讀,程式判,人核對。每一步有報告,沒有黑箱。

系統不是取代老師的判斷,而是把判斷寫下來、對得上、存得住。



共同底層: Supabase papers · questions · skills · error_patterns · guide_objectives · question_analyses · students · attempts

一條題目(question object)帶着什麼

question_key	重抽也不會變的 id(卷 + 題號 hash);所有分析、答卷都掛在它上面
text / options	題目原文、四個選項;圖表文字和圖片兩樣都保留
diagram	由 PDF 裁出的 PNG,Solver 和 Grader 都會看到
answer	由 marking scheme(另一份 PDF)配對合併
level / module	中四、S.4、Form 4 → F4;必修 / M1 / M2
depends_on	小題靠哪條小題:(b) 用 (a) 的結果
provenance	頁碼、run id、model、prompt 版本

三道關卡

- 1

驗證器

題號連續、選項齊全、要圖的題有圖、小題依賴不成環。十幾條固定規則,有問題就列出來,不會靜靜入庫。
- 2

.md 報告

每份卷一份人讀的報告:每題原文、選項、圖、答案、出了什麼問題。老師核對的是報告,不是 JSON。
- 3

兩次 run 對比

同一份卷再抽一次,逐題比:哪題文字變了、哪題選項不同。這是捉到模型「作嘢」的唯一方法。

支援:MC · 長題 · 小題 · 圖表 · 另一份 marking scheme PDF · M1 / M2 · 批量處理

556

atomic skills
技能

139

error patterns
錯誤模式

328

學習目標
由指引 PDF 抽出

一粒技能長這樣(taxonomy/skills.csv)

skill_id	name_zh	form	F / N	prerequisites	guide_ref
na.func.vertex-form	以配方法求最大 / 最小值	F4	N	na.quad.complete-square	CP-2.4
na.func.vertex-formula	以 $x = -b/2a$ 求頂點再代回	F4	F	na.func.quadratic-graph; na.formula.substitute	CP-2.3; CP-2.4
na.quad.solve-factor	以因式分解法解二次方程	F4	F	na.factor.complete	CP-1.1
ms.mensur.rect-tri-area	長方形、三角形、平行四邊形、梯形面積	F1	F	—	KS2

	維度	問的是什麼	低 → 高 的例子
R	Recognition 認	學生要不要先「看出」什麼？	$9a^2 - 25$ 一看是平方差(1) → 方程其實是 $\log_2 x$ 的二次式(3)
P	Procedure 做	程序有多長、多容易累積錯？	一次代入(1) → 帶參數的多階段代數(3)
D	Decision 揀	有沒有方法要揀？題目有沒有提示？	「利用配方法」(0) → 要自己設 sub-goal、輔助線(3)
I	Integration 連	要連起多少個單元的知識？	同一單元幾粒技能(1) → 三角 + 坐標幾何(2)
C	Cognitive depth 想	順推,還是要倒推、分情況、驗證？	順序步驟(1) → 「你是否同意」要建構論證(3)
E	Error exposure 錯	這題容易暴露哪一類錯誤？	符號小失誤(1) → 錯了得出「看似合理」的答案(3)

三個原則

- 1 不加總。
每個字母 0–3 級,是序數不是分數。一題 = 一個向量 + 哪幾個字母主導(≥ 2)。
- 2 只看題目。
不看分數、題號位置、學生數據。
- 3 可觀察。
每一級是準則,不是形容詞: 兩位老師看同一題應落同一數。

寫法: **R2 P2 D1 I2 C2 E1** — 六個數字並列,不是一個總分。「這題難」在系統裡永遠是「這題難在 R 和 C」。
每一級都要附 evidence(從題目引證);Analyzer 的 prompt 由程式裡同一份標準生成,人讀的 rubric 與模型讀的是同一份字。

	0	1	2	3
R	要處理的對象直接寫明	一個標準形式,符號本身已提示 $9a^2 - 25$	要先看出隱藏結構或重新解讀 $225x^2$ 看成 $(15x)^2$; 「兩相異交點」即 $\Delta > 0$	認出來是整題關鍵,而且沒有任何提示 方程其實是 $\log_2 x$ 的二次式
P	讀個值、講個事實	一個短的標準程序 套一個公式、一次代入	幾個程序串起,或因分數 / 根式 / 參數 / 配方 / 長除法而變複雜	長鏈,錯誤會累積 帶參數多階段代數;要分情況的程序
D	題目寫明方法,或只有一個方法 「利用配方法」 「由此」	課題的標準方法直接用得	兩個以上可行方法要揀,或次序有影響 平方差還是先提公因式;代數還是圖像	要自己設計策略 設 sub-goal、輔助線、輔助變量
I	一粒 atomic skill	同一單元幾粒技能 因式分解再解方程	兩個不同單元要連起 三角 + 坐標幾何;百分數 + 對數	三個以上單元,或要在 representation 之間轉換 幾何事實 $\rightarrow$ 代數條件 $\rightarrow$ 不等式
C	一步直接	順序步驟,每步由上一步決定,只向前	由結果倒推條件、分情況、檢驗 / 剔除候選解、「試解釋」要計數比較	證明、推廣、評估一個宣稱(建構論證或反例) 「某人宣稱……你是否同意」
E	沒有常見錯誤模式適用	一個學生自己會發現的小失誤 符號、算術	詞彙表裡某個 misconception 直接被觸發,或兩個以上失誤位 不等式乘負數不變向;對數底錯	幾個 misconception 同時,或錯了得出「看似合理」的答案 三角方程漏第二個解

2526 中四下學期 卷二 · Q24(MC)

曲線 $y = -2x^2 + 28x + 30$ 與 x 軸相交於 A、B 兩點,P 為曲線上一點。求 $\triangle APB$ 面積的最大值。

A. 128 B. 896 C. 960 D. 1024(平方單位) 答案 D
技能:配方法求極值 · 因式分解解二次方程 · 三角形面積
主策略:由截距求底,由頂點求高

- 1 $-2x^2 + 28x + 30 = 0 \Rightarrow x^2 - 14x - 15 = 0 \Rightarrow (x - 15)(x + 1) = 0$
- 2 根 -1、15,底 $AB = 15 - (-1) = 16$
- 3 面積最大 $\Leftrightarrow P$ 的 y 坐標最大 $\Leftrightarrow P$ 是頂點
- 4 頂點 $x = -28 / (2 \times (-2)) = 7$
- 5 最大 $y = -2(7)^2 + 28(7) + 30 = 128$
- 6 最大面積 $= \frac{1}{2} \times 16 \times 128 = 1024$

會暴露的錯誤:err.factor.cross-wrong-pair(十字相乘配錯因子)

R2

P2

D1

I2

C2

E1

主導:R P I C

R2

P2

D1

I2

C2

E1

對照 Q17: $f(x) = -9 - 4x$,求 $f(-1)$

R0

P1

D0

I0

C0

E1

一步代入,只考負負得正

Q24 的難不在「有伏」(E 只有 1),而在結構深:要認、要連、要想。這個分別,總分 1 分 / 0 分記不下來;六個字母記得下來。

同一條 Q24 答錯,三個學生,三種補救

學生的表現	維度	老師的判斷
交白卷,或亂算一堆沒有方向	R	不是不會計,是不知道入手點——教「拆題」,不是再操練公式
求了根、求了頂點,卻沒有把兩者接起來	I / C	單元內每樣都會,跨單元不會——出綜合題,不是單元練習
答 A(128:把最大高當作面積)或 B(896:底當 14)	E	概念全對,只是不小心——提醒即可,不用重教

沒有 RPDICE,三個都是「Q24 錯,再做十條類似題」。

一句總結

RPDICE 把老師本來就有的直覺——「這題難在要先看出來」——變成可以記錄、可以比較、可以跟進的數據。系統不是取代判斷,是把判斷存下來、放大。

出卷:控制「難在哪裡」

這份中四卷 40 題:沒有一題任何維度到 3 級;一半(20 題)六個維度全部 ≤ 1 ;只有 4 題有四個維度到 2。這是一份測熟練度的卷——是不是你想要的,一眼可判。想加「要思考」的題,加的是 R2 / D2,不是把數字弄複雜(那只是 P)。

教學:逐級搭梯

同一條題每次只動一個字母(下一頁),學生每一步只面對一個新難處。這是「引導」與「派簡單題」的分別。

對學生、對家長:講得出的一句話

「他不是數學差,是三步以上的題接不起來(C);單步的題全對。」比「62 分」有用,學生也聽得明白該練什麼。

題庫:判斷可以累積

每條分析過的題目帶着六個維度、技能、錯誤存進題庫。下一年出卷、下一班補底,按維度和技能搜,不靠記憶。

改動	字母	為什麼
加一句「當 P 為頂點時,△APB 面積最大」	R 2 → 1	要認的東西已經寫明,剩下的是程序
加「利用配方法求頂點的 y 坐標」	D 1 → 0	題目印着方法,D 封頂在 0-1
改為 $y = -3x^2 + 7x + 6$	P 2 → 3	根 $-\frac{2}{3}$ 與 3、頂點 $x = 7/6$,分數運算貫穿全題,錯誤會累積
改為 $y = -2x^2 - 28x + 30$	E 1 → 2	根 -15 與 1、頂點 $x = -7$,三個符號位;直接觸發「頂點符號錯」這個 misconception。答案仍是 1024——錯了也可能湊回對答案
加問「並求直線 AP 的方程」	I 2 → 3	二次函數 + 二次方程 + 面積 + 坐標幾何,四個單元
改為「有人宣稱 △APB 的面積可以超過 1000,你是否同意?試解釋。」	C 2 → 3	要評估一個宣稱、建構論證,不再是順推到一個數

每一步只面對一個新難處——這就是將來「出題器」生成變體的原理:不是隨機改數字,而是指定要動哪一個字母。



每個策略的結果：一個 status

confirmed

proposed

unverified

rejected

每個策略有穩定的 strategy_id(由名稱 + 技能生成,重跑不變)、source(analyzer / student / teacher)。學生用另一種方法,就以 source: student 加到那題下面。

這份卷真跑的結果

- 40 個策略全部解過;Critic 報 5 個 issue。
- Q38 LEVEL_OVERRATED:C 評 2,Critic 指全部是順推步驟,按準則應為 1。
- Q9 SKILL_IRRELEVANT:列了「二次公式」,實際是開方直接解。
- Q7、Q20 要看圖:Solver 只有文字時解不到 → 現在連圖送;仍解不到就標 unverified,不當 rejected。
- 所有 code 都是固定清單;清單外的一律 CRITIC_OTHER。程式已報過的,Critic 不重複報。

28 / 40

題有東西變了

25 / 240

個字母移了一級(10%)

D

飄得最多(7 次)

16 題

技能列表有變

1 題

主策略換了(Q18)

這代表什麼

我們怎樣對付它

- 量:diff_analyses 一條命令,逐題列出哪個字母、哪粒技能、主策略有沒有換。
- 錨:30 條人手評分的黃金集,每次改 prompt 都對回去(每個維度 exact / ± 1 / 偏向)。這 30 條需要老師核對。
- 驗:Solver / Critic 是第二層獨立意見,已捉到 Q38 的 C 評高。
- 下一步:同一題跑 N 次取眾數。等多幾份卷的數據再定 N。

完整逐題差異:docs/deviations_from_guide.md §46;命令:python3 -m scripts.diff_analyses 2526_2nd_S4MATH2

$y = -2x^2 + 28x + 30$ 的圖像與 x 軸相交於 A 和 B 兩點。P 是該圖像上的一點，其中 P 的 y 坐標是正數。求 $\triangle APB$ 的最大面積。

頂點的 x 坐標

$$x = \frac{28}{2(-2)} = 7$$
$$y = 2(7)^2 + 28(7) + 30$$
$$= -98 + 196 + 30$$
$$= 128$$
$$\therefore a = -2 < 0$$
$$y_{\max} = 128$$

最大面積： $[\triangle APB]_{\max} = \frac{1}{2} \times 16 \times 128$

$$= 8 \times 128$$
$$= 1024$$

同一頁底部:圈了 D

A. 128 平方單位
B. 896 平方單位
C. 960 平方單位
D. 1024 平方單位

模型逐行照抄(寫錯也照抄,不准修正)

頂點的 x 坐標

$$x = 28 / 2(-2) = 7$$
$$y = 2(7)^2 + 28(7) + 30$$
$$= -98 + 196 + 30$$
$$= 128$$
$$\therefore a = -2 < 0$$
$$y_{\max} = 128$$

最大面積： $[\triangle APB]_{\max} = \frac{1}{2} \times 16 \times 128$

$$= 8 \times 128$$
$$= 1024$$

兩處抄寫失誤(slip)被保留:漏了 $-b/2a$ 的負號、漏了 $-2(7)^2$ 的負號——結果卻是對的。
模型不會收到標準答案;否則它會「好心」把 $2(7)^2$ 讀成 $-2(7)^2$, slip 就消失了。

程式對回題目的分析

對錯 答對:D(1024)。對照來源:Solver 確認的答案(這份卷沒有 marking scheme)

路線 對回主策略 4d318b39052c:由頂點求高。學生沒有解方程,底 16 直接寫出

技能證據 ✓ 三角形面積
✓ $x = -b/2a$ 求頂點(改用了公式法,不是配方法)
✗ 因式分解解二次方程:紙上沒有證據

錯誤 2 個 slip(漏負號,結果正確);沒有 misconception

信心 0.95;不需要人手覆核

「答對但不是全對」——MC 的 ✓ 記不到,attempt 記得到。

Supabase 裡的表

表	一行是	關鍵欄位
papers · questions	一份卷、一條題目	question_key(穩定 id)、text、options、diagram、answer、level、depends_on
skills · error_patterns · guide_objectives	一粒技能 / 一個錯誤 / 一條學習目標	guide_ref、foundation、prerequisites;error 掛哪些 skills
question_analyses	一條題目一次 run	strategies(jsonb: strategy_id、source、status、六個字母 + evidence)、solutions、critic_issues
students · attempts	一個學生一次作答	strategy_id、skills_evidenced、skills_not_evidenced、errors_observed、verdict、needs_human

attempts.strategy_id 指回 question_analyses 裡的策略:學生走的路線與題目的分析是同一套 id。學生用了新方法,就以 source: student 加回那條題目。

未做的三件事(按這個次序)

- 1

學生模型

由 attempts 聚合出每個學生每粒技能的掌握度(skill_mastery):證據次數、slip 與 misconception 的比例、最近一次。
- 2

校準

RPDICE 是「題目應該有多難」,attempts 是「實際有多難」。兩者對回去:E 對真實錯誤率、C 對答錯的分佈,調準標準。
- 3

適性練習 / 出題器

按第 10 頁的原理生成變體:指定要動哪個字母,對着哪粒技能,給哪個學生。

需要老師的兩件事

- ① 核對 30 條黃金集的 RPDICE 評分(標準的可靠度由此決定)
- ② 更多學生手寫頁:答錯的、用另一路線的、字跡差的

收尾

三句話

1

題目變成數據。

六個維度、技能、錯誤,全部對回課程指引;不是一個總分,是一個可以搜、可以比的向量。

2

AI 讀,程式判,人核對。

每一層有報告、有驗證、有噪音的量度;不合格的不會靜靜入庫。

3

下一步從學生的手寫頁開始。

第一張真卷已經證明可行;要走到學生模型,需要你們的卷、你們核對的 30 條黃金集。

Q & A

R

P

D

I

C

E